

Министерство науки и высшего образования Российской Федерации Федеральное государственное автономное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления»

> Курс «Технологии машинного обучения» Отчёт по лабораторной работе №6

> > Выполнила:

студентка группы ИУ5-62Б Вешторт Е.С.

Подпись:

Гещт Проверил: Гапанюк Ю.Е.

Подпись:

```
In [1]: import pandas as pd
        from sklearn.impute import SimpleImputer
        from sklearn.preprocessing import OneHotEncoder, StandardScaler
        from sklearn.compose import ColumnTransformer
        from sklearn.model_selection import train_test_split, GridSearchCV, RandomizedSearchCV, KFold
        from sklearn.neighbors import KNeighborsClassifier
        from sklearn.metrics import accuracy_score, classification_report, f1_score
        from sklearn.linear_model import LogisticRegression
        from sklearn.svm import SVC
        from sklearn.model selection import train test split
        from sklearn.ensemble import StackingRegressor, RandomForestRegressor, GradientBoostingRegres
        from sklearn.neural network import MLPRegressor
        from sklearn.linear_model import LinearRegression
        from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
        import numpy as np
        from gmdh import Combi, Mia
```

Подготовка датасета

Загрузка данных, для работы выбрала датасет с информацией о продаже машин

In [2]: df = pd.read_csv("C://Users/dielo/OneDrive/добавить/Documents/Учебное/TMO/Ла61/all_anonymized

C:\Users\dielo\AppData\Local\Temp\ipykernel_12156\746799274.py:1: DtypeWarning: Columns (7,12)
have mixed types. Specify dtype option on import or set low_memory=False.
 df = pd.read_csv("C://Users/dielo/OneDrive/добавить/Documents/Учебное/ТМО/Лаб1/all_anonymize
d 2015 11 2017 03.csv")

In [3]: df.sample(5)

[-].													
Out[3]: _		maker	model	mileage	manufacture_year	engine_displacement	engine_power	body_t					
2	2110652	volkswagen	polo	151298.0	2006.0	1198.0	47.0	0					
2	2923682	audi	200	NaN	NaN	NaN	NaN	0					
1	1848017	ford	s-max	163000.0	2010.0	1997.0	120.0	0					
	579362	fiat	marea	NaN	1999.0	1616.0	76.0	com					
3	3284050	mercedes- benz	ml320	220000.0	2001.0	NaN	NaN	0					
	4												

In [4]: df.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3552912 entries, 0 to 3552911
Data columns (total 16 columns):
# Column
                       Dtype
--- -----
                       ----
0 maker
                     object
                     object
1 model
2 mileage
                     float64
3 manufacture year float64
4 engine_displacement float64
5
   engine power
                    float64
                    object
object
6 body_type
7 color_slug
8 stk_year
                     float64
                    object
float64
float64
9 transmission
10 door count
11 seat_count
                    object
object
12 fuel_type
13 date_created
14 date_last_seen
                       object
15 price_eur
                       float64
dtypes: float64(8), object(8)
memory usage: 433.7+ MB
```

Столбцы с годами, количеством дверей и сидений, преобразуем в целые:

```
In [5]: df[['manufacture year', 'stk year', 'door count', 'seat count']] = df[['manufacture year', 's
In [6]: missing values = df.isnull().sum()
        print("Пропущенные значения в каждом столбце:\n", missing_values[missing_values > 0])
      Пропущенные значения в каждом столбце:
       maker
                              518915
      model
                           1133361
      mileage 362584
manufacture_year 370578
      engine displacement 743414
                            554877
      engine_power
                           1122914
      body type
                           3343411
      color_slug
      stk year
                           3016807
      transmission
                            741630
      door_count
                           1090066
      seat_count
                           1287099
      fuel_type
                            1847606
      dtype: int64
```

Сперва заполним пропуски в столбцах maker и model, т.к. в дальнейшем будем опираться на них для заполнения столбцов со свойствами машин Можно было бы заполнить каждый столбец модой, но тогда может получиться что-нибудь странное вроде opel octavia, что не будет соответсвовать ни одному существующему автомобилю и может испортить дальнейшие заполнения свойств Поэтому логика заполнения будет следующая: если известен производитель, берем самую частую его модель в датасете (если производитель больше в датасете не встречается, будем заполнять строкой 'unknown'), если известна модель, ищем самого частого ее производителя (на случай совпадения названий), иначе также пишем 'unknow' Если нет ни того, ни другого, то ищем самую частую пару производитель-модель, и заполняем этими значениями столбцы

```
In [7]: def fill_maker_model(df):
            maker_to_model = (
                df.dropna(subset=['maker', 'model'])
                  .groupby('maker')['model']
                  .agg(lambda x: x.mode().iloc[0] if not x.mode().empty else 'unknown')
                  .to_dict()
            )
            model to maker = (
                df.dropna(subset=['maker', 'model'])
                  .groupby('model')['maker']
                  .agg(lambda x: x.mode().iloc[0] if not x.mode().empty else 'unknown')
                  .to dict()
            )
            most_common_pair = (
                df.dropna(subset=['maker', 'model'])
                   .groupby(['maker', 'model'])
                  .size()
                  .sort_values(ascending=False)
                  .idxmax()
            )
            mask model missing = df['model'].isna() & df['maker'].notna()
            df.loc[mask_model_missing, 'model'] = df.loc[mask_model_missing, 'maker'].map(
                lambda maker: maker_to_model.get(maker)
            )
            mask_maker_missing = df['maker'].isna() & df['model'].notna()
            df.loc[mask_maker_missing, 'maker'] = df.loc[mask_maker_missing, 'model'].map(
                lambda model: model_to_maker.get(model)
            )
            mask both missing = df['maker'].isna() & df['model'].isna()
            df.loc[mask_both_missing, 'maker'] = most_common_pair[0]
            df.loc[mask_both_missing, 'model'] = most_common_pair[1]
            return df
```

```
In [8]: df = fill_maker_model(df)
```

Теперь, когда у каждой машины есть производитель и модель, заполним свойства автомобилей, которые те имеют с момента производства (год производства, количество дверей и т.д.), наиболее часто встречающимися по машинам того же производителя той же модели Если модель в единственном экземпляре в датасете, то наиболее часто встречающимися по производителю А если производитель в свою очередь в единственном экземпляре - то модой по всему столбцу

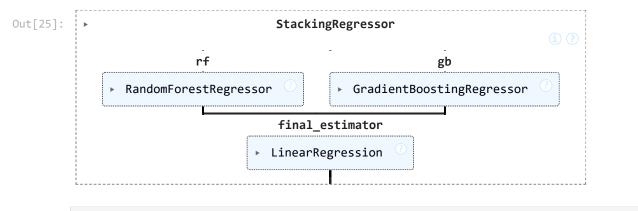
```
global_mode = df[columns_to_fill].mode().iloc[0]
             df = df.merge(maker_model_mode, on=['maker', 'model'], how='left', suffixes=('', '_mode')
             df = df.merge(maker_mode, on='maker', how='left', suffixes=('', '_maker_mode'))
             for col in columns to fill:
                 df[col] = df[col].fillna(df[f'{col}_mode'])
                 df[col] = df[col].fillna(df[f'{col} maker mode'])
                 df[col] = df[col].fillna(global_mode[col])
             df = df.drop(columns=[f'{col}_mode' for col in columns_to_fill] + [f'{col}_maker_mode' fo
             return df
         properties_columns = ['manufacture_year', 'stk_year', 'door_count', 'seat_count',
In [10]:
                            'engine_power', 'body_type', 'transmission', 'fuel_type']
         df = fill_car_properties(df, properties_columns)
         Оставшиеся столбцы заполним просто модой для категориальных и средним для числовых
In [11]:
         categorical_cols = df.select_dtypes(include=['object']).columns
         numerical_cols = df.select_dtypes(include=['float64']).columns
In [12]: cat_imputer = SimpleImputer(strategy='most_frequent')
         df[categorical_cols] = cat_imputer.fit_transform(df[categorical_cols])
In [13]: num_imputer = SimpleImputer(strategy='mean')
         df[numerical_cols] = num_imputer.fit_transform(df[numerical_cols])
         Переведем даты в ts (int64):
In [14]: df['date_last_seen'] = pd.to_datetime(df['date_last_seen'], format='IS08601').astype('int64')
         df['date_created'] = pd.to_datetime(df['date_created'], format='IS08601').astype('int64')
In [15]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3552912 entries, 0 to 3552911
Data columns (total 16 columns):
 # Column
                            Dtype
--- -----
                            ----
 0 maker
                          object
 1 model
                           object
 2 mileage
                           float64
 3 manufacture_year Int64
 4 engine_displacement float64
 5
    engine_power
                         float64
6 body_type object
7 color_slug object
8 stk_year Int64
8 stk_year
9 transmission object
10 door_count Int64
11 seat_count Int64
12 fuel_type object
13 date_created int64
13 date_created
14 date_last_seen int64
15 price eur float6
 15 price_eur
                            float64
dtypes: Int64(4), float64(4), int64(2), object(6)
memory usage: 447.3+ MB
```

Закодируем категориальные признаки при помощи ОНЕ:

Out[18]:		maker_audi	maker_bentley	maker_bmw	maker_chevrolet	maker_chrysler	maker_citroen	maker_d
	0	0.0	0.0	0.0	0.0	0.0	0.0	
	1	0.0	0.0	0.0	0.0	0.0	0.0	
	2	0.0	0.0	0.0	0.0	0.0	0.0	
	3	0.0	0.0	0.0	0.0	0.0	0.0	
	4	0.0	0.0	0.0	0.0	0.0	0.0	
	5	1.0	0.0	0.0	0.0	0.0	0.0	
	6	0.0	0.0	0.0	0.0	0.0	1.0	
	7	0.0	0.0	0.0	0.0	0.0	0.0	
	8	0.0	0.0	0.0	0.0	0.0	0.0	
	9	0.0	0.0	0.0	0.0	0.0	0.0	

10 rows × 740 columns



In [26]: mlp = MLPRegressor(hidden_layer_sizes=(50,), max_iter=2000, verbose = True, random_state=42,
 mlp.fit(X_train, y_train)

Iteration 1, loss = 18367656740.09548950

Validation score: -0.427516

Iteration 2, loss = 18343366433.29713821

Validation score: -0.185694

Iteration 3, loss = 18304613455.67306900

Validation score: 0.092584

Iteration 4, loss = 18269312115.70410156

Validation score: 0.268786

Iteration 5, loss = 18246877869.32195663

Validation score: 0.358536

Iteration 6, loss = 18233953232.92250824

Validation score: 0.404291

Iteration 7, loss = 18225328522.12657166

Validation score: 0.431483

Iteration 8, loss = 18219603333.62150192

Validation score: 0.449229

Iteration 9, loss = 18215304969.45560074

Validation score: 0.459470

Iteration 10, loss = 18211764635.41940689

Validation score: 0.468554

Iteration 11, loss = 18208741951.88881302

Validation score: 0.476989

Iteration 12, loss = 18206069719.82094955

Validation score: 0.486078

Iteration 13, loss = 18203626432.36535263

Validation score: 0.492557

Iteration 14, loss = 18201270702.27122498

Validation score: 0.500033

Iteration 15, loss = 18199112629.58381653

Validation score: 0.506491

Iteration 16, loss = 18196990925.88211441

Validation score: 0.512900

Iteration 17, loss = 18194998461.06058502

Validation score: 0.517453

Iteration 18, loss = 18193063957.46667480

Validation score: 0.523425

Iteration 19, loss = 18191248564.93579865

Validation score: 0.529014

Iteration 20, loss = 18189492647.34416580

Validation score: 0.532362

Iteration 21, loss = 18187691125.10905075

Validation score: 0.537519

Iteration 22, loss = 18186105647.56687546

Validation score: 0.547281

Iteration 23, loss = 18184664860.37251663

Validation score: 0.542569

Iteration 24, loss = 18182959613.62076187

Validation score: 0.547311

Iteration 25, loss = 18181538590.02111053

Validation score: 0.544859

Iteration 26, loss = 18180095486.68863297

Validation score: 0.550383

Iteration 27, loss = 18178576867.03490829

Validation score: 0.546697

Iteration 28, loss = 18177291292.05794144

Validation score: 0.548741

Iteration 29, loss = 18175995165.81284714

Validation score: 0.551202

Iteration 30, loss = 18174625293.94470596

Validation score: 0.548451

Iteration 31, loss = 18173521455.94356155

Validation score: 0.548734

```
Iteration 32, loss = 18172264243.36838150
        Validation score: 0.550418
        Iteration 33, loss = 18171046539.33911896
        Validation score: 0.549376
        Iteration 34, loss = 18169835215.56095505
        Validation score: 0.548564
        Iteration 35, loss = 18168649252.38023758
        Validation score: 0.551318
        Iteration 36, loss = 18167574499.83300400
        Validation score: 0.548070
        Iteration 37, loss = 18166385300.25009155
        Validation score: 0.547183
        Iteration 38, loss = 18165357379.31843567
        Validation score: 0.555605
        Iteration 39, loss = 18164599493.84476471
        Validation score: 0.544320
        Iteration 40, loss = 18163033281.75092316
        Validation score: 0.543816
        Iteration 41, loss = 18161834222.80759430
        Validation score: 0.545034
        Iteration 42, loss = 18160845258.32625198
        Validation score: 0.543804
        Iteration 43, loss = 18159673839.31465530
        Validation score: 0.541723
        Iteration 44, loss = 18158723185.61074829
        Validation score: 0.539469
        Iteration 45, loss = 18157609341.42711258
        Validation score: 0.536324
        Iteration 46, loss = 18156507810.85210419
        Validation score: 0.538208
        Iteration 47, loss = 18155469154.72999954
        Validation score: 0.534962
        Iteration 48, loss = 18154426921.82211304
        Validation score: 0.537207
        Iteration 49, loss = 18153300472.99053192
        Validation score: 0.537617
        Validation score did not improve more than tol=0.000100 for 10 consecutive epochs. Stopping.
Out[26]: 🔻
                                           MLPRegressor
         MLPRegressor(early_stopping=True, hidden_layer_sizes=(50,),
                       learning_rate='adaptive', learning_rate_init=0.02, max_iter=2000,
                       random state=42, verbose=True)
In [30]: gmdh linear = Combi()
         gmdh_nonlinear = Mia()
         gmdh_linear.fit(X_train, y_train)
         gmdh_nonlinear.fit(X_train, y_train)
Out[30]: <gmdh.gmdh.Mia at 0x29cb97fc990>
In [42]: def evaluate(model, name):
             y pred = model.predict(X test)
             print(f"{name}:\n"
             f" MAE: {mean_absolute_error(y_test, y_pred):.4f}\n"
             f" RMSE: {mean_squared_error(y_test, y_pred)**0.5:.4f}\n"
             f" R<sup>2</sup>: {r2_score(y_test, y_pred):.4f}\n")
```

```
In [43]: evaluate(stack_model, "Stack")
    evaluate(mlp, "MLP")
    evaluate(gmdh_linear, "COMBI")
    evaluate(gmdh_nonlinear, "MIA")
```

Stack:

MAE: 17602.3924 RMSE: 423945.3950 R²: -0.0002

MLP:

MAE: 13407.4461 RMSE: 423899.5553 R²: 0.0000

COMBI:

MAE: 16488.0649 RMSE: 423841.9025 R²: 0.0003

MIA:

MAE: 15749.1855 RMSE: 423758.3399 R²: 0.0007